



**Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»**

**Отчет по рубежному контролю №1
по дисциплине «Методы машинного обучения в АСОИУ»
Вариант №5, 25**

**Выполнил:
студент группы ИУ5Ц-21М
Чудновский З.А.
подпись, дата**

**Проверил:
к.т.н., доц., Гапанюк Ю.Е.
подпись, дата**

2026 г.

СОДЕРЖАНИЕ

1. Требования по группам	3
2. Дополнительные требования по группам.....	3
3. Условия задач	3
4. Ход работы (листинг)	4

1. Требования по группам

Для студентов групп ИУ5-21М, ИУ5-22М, ИУ5-23М, ИУ5-24М номер варианта = номер в списке группы.

2. Дополнительные требования по группам

Для студентов групп ИУ5-21М, ИУ5И-21М - для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Каждая задача предполагает использование набора данных. Набор данных выбирается Вами произвольно с учетом следующих условий:

- Вы можете использовать один набор данных для решения всех задач, или решать каждую задачу на своем наборе данных.
- Набор данных должен отличаться от набора данных, который использовался в лекции для решения рассматриваемой задачи.
- Вы можете выбрать произвольный набор данных (например тот, который Вы использовали в лабораторных работах) или создать собственный набор данных (что актуально для некоторых задач, например, для задач удаления псевдоконстантных или повторяющихся признаков).
- Выбранный или созданный Вами набор данных должен удовлетворять условиям поставленной задачи. Например, если решается задача устранения пропусков, то набор данных должен содержать пропуски.

Наборы данных

Набор данных о выживаемости уличных торговцев едой в городах (Индия): <https://www.kaggle.com/datasets/mdwaquarazam/television-dataset-2022>

3. Условия задач

Номер задачи №1 (Задача №5)

Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "one-hot encoding".

Номер задачи №2 (Задача №25)

Для набора данных для одного (произвольного) числового признака проведите обнаружение и удаление выбросов на основе межквартильного размаха.

4. Ход работы (листинг)

Для начала импортируем необходимые библиотеки и загружаем датасет. При загрузке были учтены особенности структуры файла TELEVISION.csv (использован движок python для обработки некорректных строк).

```
# Загрузка данных
df = pd.read_csv('TELEVISION.csv', engine='python', on_bad_lines='skip')
```

```
df['current_price'] = df['current_price'].replace({'₹': '', ',': ''}, regex=True).astype(float)
```

```
# 2. Просмотр структуры
print(df.head())
```

```
# 2. Просмотр структуры
print(df.head())
```

	Product_Name	Stars	Ratings	Reviews	current_price	MRP	\
0	Croma	4.2	1773	217	7990.0	₹20000	
1	Adsun	3.8	6742	930	8699.0	₹21999	
2	LG	4.4	38870	3443	16499.0	₹21990	
3	OnePlus	4.3	101256	9189	16499.0	₹21999	
4	Xiaomi	4.3	3120	305	15499.0	₹24999	

	channel	\
0	HD Ready 1366 x 768 Pixels	
1	Netflix Disney+Hotstar Youtube	
2	Netflix Prime Video Disney+Hotstar Youtube	
3	Netflix Prime Video Disney+Hotstar Youtube	
4	Netflix Prime Video Disney+Hotstar Youtube	

	Operating_system	Picture_qualtiy	\
0	20 Speaker Output	60 Hz Refresh Rate	
1	Operating System: Android Based	HD Ready 1366 x 768 Pixels	
2	Operating System: WebOS	HD Ready 1366 x 768 Pixels	
3	Operating System: Android	HD Ready 1366 x 768 Pixels	
4	Operating System: Android	HD Ready 1366 x 768 Pixels	

Далее проверяем датасет на наличие пропусков:

```
print(df.isnull().sum())
```

```
Product_Name      0
Stars             0
Ratings           0
Reviews           0
current_price     0
MRP              0
channel           0
Operating_system  0
Picture_qualtiy   0
Speaker           0
Frequency         0
Image_url         0
dtype: int64
```

Как видно из вывода, пропусков в датасете нет (все значения равны 0), поэтому дополнительная обработка пропусков не потребовалась.

Задача №5

Для набора данных проведено кодирование категориального признака `channel` с использованием метода "one-hot encoding". Это преобразование необходимо для корректного представления качественных данных в моделях машинного обучения.

Задаем столбец, который кодируем: `cat_col = 'channel'`

Выполняем кодирование и ПРИСВАИВАЕМ результат в `df_ohe`:

```
df_ohe = pd.get_dummies(df, columns=[cat_col])
```

Выводим результат: `print(df_ohe.head())`

	Product_Name	Stars	Ratings	Reviews	current_price	MRP	\
0	Croma	4.2	1773	217	7990.0	₹20000	
1	Adsun	3.8	6742	930	8699.0	₹21999	
2	LG	4.4	38870	3443	16499.0	₹21990	
3	OnePlus	4.3	101256	9189	16499.0	₹21999	
4	Xiaomi	4.3	3120	305	15499.0	₹24999	

	Operating_system	Picture_qualitiy	\
0	20 Speaker Output	60 Hz Refresh Rate	
1	Operating System: Android Based	HD Ready 1366 x 768 Pixels	
2	Operating System: WebOS	HD Ready 1366 x 768 Pixels	
3	Operating System: Android	HD Ready 1366 x 768 Pixels	
4	Operating System: Android	HD Ready 1366 x 768 Pixels	

	Speaker	Frequency	... channel_Prime video Youtube	\
0	2 x HDMI 2 x USB	1 Year Warranty	...	False
1	20 W Speaker Output	60 Hz Refresh Rate	...	False
2	10 W Speaker Output	50 Hz Refresh Rate	...	False
3	20 W Speaker Output	60 Hz Refresh Rate	...	False
4	20 W Speaker Output	60 Hz Refresh Rate	...	False

	channel_Ultra HD (4K) 1920 x 1080 Pixels	\
0	False	
1	False	
2	False	
3	False	
4	False	

	channel_Ultra HD (4K) 3840 * 2160 Pixels	\
0	False	
1	False	
2	False	
3	False	
4	False	

	channel_Ultra HD (4K) 3840 x 2160 - Ultra HD Pixels	\
0	False	
1	False	
2	False	
3	False	
4	False	

	channel_Ultra HD (4K) 3840 x 2160 Pixels	\
0	False	
1	False	
2	False	
3	False	
4	False	

	channel_Ultra HD (4K) 3840 x 2160 pixels Pixels	\
0	False	
1	False	
2	False	
3	False	
4	False	

В результате для каждой уникальной категории в столбце channel был создан отдельный бинарный признак. Это преобразование позволило перевести качественные данные в количественный формат, что необходимо для дальнейшего анализа.

Задача №25

Для набора данных для одного (произвольного) числового признака проведите обнаружение и удаление выбросов на основе межквартильного размаха.

Проведено удаление выбросов для признака `current_price` на основе межквартильного размаха.

```
num_col = 'current_price'
```

```
Q1 = df[num_col].quantile(0.25)
Q3 = df[num_col].quantile(0.75)
IQR = Q3 - Q1
```

```
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
```

```
outliers = df[(df[num_col] < lower_bound) | (df[num_col] > upper_bound)]
print("Количество выбросов:", outliers.shape[0])
print(outliers[[num_col]].head())
```

Результат:

Количество выбросов: 87	
	current_price
258	119999.0
272	146300.0
299	149990.0
332	499990.0
337	107990.0

```
print("Размер до удаления выбросов:", df.shape)  
print("Размер после удаления выбросов:", df_clean.shape)
```

Размер до удаления выбросов: (882, 12)

Размер после удаления выбросов: (795, 12)

Удаление 87 аномальных значений (премиальный сегмент цен) позволило сделать данные для обучения модели более однородными и корректными.